



DEEP LEARNING APPLIED TO BIOIMAGE ANALYSIS

Segmentación de Núcleos Celulares

CNN simple vs U-Net, con y sin Data
Augmentation



INTEGRANTES DEL PROYECTO:

- Noelia Fernandez
- Piero Pastor
- Angel Blas
- Renato Martínez

🎯 Objetivo y Dataset MoNuSeg

Objetivo Principal

Comparar dos arquitecturas de segmentación semántica:

- **CNN encoder-decoder simple** (sin skip connections).
- **U-Net** (con skip connections).

Medir el impacto directo de aplicar Data Augmentation sobre un dataset pequeño.

📁 MoNuSeg 2018 (Kaggle)

Imágenes de histopatología con tinción H&E e imágenes binarias de máscaras de núcleos celulares.

82

Pares
Totales


66

Entrenamiento


16

Prueba
(Test)

Muestra del Dataset: Imagen H&E vs Máscara Binaria



Metodología: Pipeline del Proyecto



Función de Pérdida

Dice + BCE Combinadas

Equilibra la precisión a nivel píxel (BCE) con el solapamiento global de región (Dice Loss).

Métrica de Evaluación

IoU (Intersection over Union)

Jaccard Index evaluado con un umbral de binarización de 0.5 sobre el conjunto de test.

Configuración de Entrenamiento

* Ambos modelos entrenados desde cero (sin transfer learning).

Hiperparámetro	Valor Configurado
Épocas	15
Batch size	4
Learning rate	1e-3 (Adam)
Partición Train / Test	80% / 20% (aleatoria)
Tamaño de imagen	128 x 128 px
Dropout (CNN)	20%

Optimización

El entrenamiento usa el optimizador Adam con una tasa de aprendizaje fija y lotes pequeños, típico para datasets médicos reducidos como MoNuSeg.

Datos y Regularización

El dataset se divide antes de entrenar y se aplican técnicas de dropout y aug para evitar el sobreajuste dado el tamaño reducido del set de entrenamiento (66 imágenes).

Arquitecturas Comparadas

CNN Simple

- 🟢 **Encoder:** 3 bloques Conv2D + BatchNorm + MaxPool.
- 🟢 **Decoder:** 3 capas ConvTranspose2D.
- ✖ **Sin skip connections.**
- ⚠ Pierde detalle espacial fino en el proceso de downsampling.

Input → Enc → Dec → Output

U-Net

- ✓ Misma profundidad que la CNN simple.
- ✓ **Skip Connections ([torch.cat](https://pytorch.org/docs/stable/torch.cat.html)):** Concatena mapas de características del encoder directamente al decoder.
- ✓ Preserva bordes y detalles finos de los núcleos celulares.
- ★ Muy superior para la segmentación de estructuras pequeñas.

Enc → Skip → Dec

⊘ Entrenamiento sin Data Augmentation

IoU = 0.00

En ambos modelos (CNN y U-Net)

⚠ Colapso de Predicción


Con solo 66 imágenes de entrenamiento, ambos modelos colapsaron completamente: aprendieron a predecir **"todo fondo"** (máscaras totalmente negras) en lugar de segmentar los núcleos.

El dataset era demasiado pequeño para generalizar sin variabilidad adicional.

Simulación de Salida del Modelo (Test)


CNN Simple

U-NET



Comparación de Entrenamiento (Sin DA)

Evolución de Pérdida (Loss) vs Épocas



Ilusión de Convergencia

Aunque la curva de pérdida disminuye constantemente desde ~1.36 hasta ~1.04 en ambas redes, este descenso no produjo ninguna segmentación efectiva.

✖ Causa Raíz

El modelo optimizó la pérdida prediciendo el valor dominante (el fondo binario), cayendo en un mínimo local del cual no pudo salir sin variabilidad de datos.


🔄 Data Augmentation: Rotaciones Sincronizadas

🔄 Estrategia de Augmentation

Para combatir el tamaño reducido del dataset (66 imágenes de entrenamiento), se aplicó una **rotación aleatoria (entre -90° y 90°)** con 50% de probabilidad en cada iteración.

- ✓ **Sincronización:** Se utiliza `TF.rotate` para rotar la imagen y la máscara exactamente con el mismo ángulo θ .
- ✓ **Solo en Train:** Solo se aplica al set de entrenamiento.
- ✓ **Test intacto:** El set de prueba se mantiene sin augmentation para una evaluación realista.
- ✓ Aumenta la variabilidad efectiva sin generar datos falsos.

Proceso de Rotación Sincronizada (θ)



🔧 Entrenamiento con Data Augmentation


🧠 La Augmentation Rescató a Ambos Modelos

Al añadir rotaciones sincronizadas, ambos modelos pasaron de **IoU = 0.00** a valores de segmentación positivos y funcionales.


Además, **U-Net (0.37)** supera claramente a la **CNN simple (0.28)**: las skip connections le permiten aprovechar mejor la mayor variabilidad introducida por las rotaciones.

Predicciones con Data Augmentation (Test)

CNN Simple (IoU = 0.28)




U-Net (IoU = 0.37)



Comparación de Entrenamiento (Con DA)

Evolución de Pérdida (Loss) vs Épocas



Pasaron de IoU = 0.00 a valores positivos en ambos casos. Además, U-Net (0.37) supera claramente a la CNN simple (0.28): las skip connections le permiten aprovechar mejor la mayor variabilidad introducida por las rotaciones.

Resultados Finales y Métricas IoU

0.00

Sin Data Augmentation (Ambos)

0.28

CNN Simple + Augmentation

0.37

U-Net + Augmentation



Configuración de Experimento	Data Augmentation	Comportamiento de Red	Métrica IoU (Test)
CNN Encoder-Decoder Simple	Desactivado	Colapso a todo fondo	0.00
U-Net con Skip Connections	Desactivado	Colapso a todo fondo	0.00
CNN Encoder-Decoder Simple	Rotación Sincronizada	Recupera segmentación tosca	0.28
U-Net con Skip Connections	Rotación Sincronizada	Segmentación de bordes finos	0.37 ★

Conclusiones Clave

1. El Data Augmentation fue decisivo

Sin él, ambos modelos colapsaron a $\text{IoU} = 0$ por el tamaño reducido del dataset (66 imágenes de entrenamiento). Las rotaciones sincronizadas salvaron el entrenamiento.

2. U-Net superó a la CNN simple

Alcanzó **0.37 vs 0.28 de IoU** con augmentation, gracias a las skip connections que preservan el detalle espacial fino de los núcleos celulares.

3. La arquitectura importa tanto como los datos

Ni el mejor modelo compensa un dataset insuficiente, ni el mejor dataset compensa una arquitectura sin skip connections.